Supersonic Algorithms

Anton Rodenwald

11. Januar 2023

Projektbetreuerin: Birgit Ziegenmeyer

Institution: Schillerschule Hannover

Thema des Projektes: Analyse verschiedener Implementationen von Algorith-

men in Bezug auf die besten Techniken zur Optimierung und Auseinandersetzung mit der Ausführung dieser,

um die Umsetzung hochperformanter und effizienter

Programme zu erforschen.

Fachgebiet: Mathematik/Informatik

Wettbewerbssparte: Jugend Forscht Bundesland: Niedersachsen

Wettbewerbsjahr: 2023

Kurzfassung

Nachdem wir im Informatikunterricht der SEK II Sortieralgorithmen behandelt hatten, stellte ich mir die Frage, wie man am schnellsten eine Liste von 10 Millionen zufällig Generierten Zahlen sortieren kann und welche Programmiersprache und welche Techniken man nutzen sollte. Daraus entwickelte sich dann die etwas allgemeinere Fragestellung, nämlich welche Optimierungen erhöhen die Ausführgeschwindigkeit von Programmen am meisten und wieso? Mir war bekannt, dass Python, was wir im Unterricht verwendet hatten, als eine der langsamsten Sprachen gilt, weswegen ich neben Python auch noch C++ wählte, was allgemein als eine der schnellsten Sprachen gilt. Ich implementierte anschließend verschiedene Variationen der Quicksort und anderer Algorithmen und testete so, in welchem Maß Optimierungsansätze die Performance beeinflussten. Dabei kam ich zu dem Ergebnis, dass die besten Python Bibliotheken zur Optimierung numpyünd numba"waren, wobei C++ trotzdem schneller war, womit sich meine Hypothese bestätigte. Dies erklärte ich mir dadurch, dass Python eine Interpretierte und C++ eine kompilierte Sprache ist, diese beiden Sprachen also gänzlich verschiedenen sind und somit auch die Möglichkeiten zur Optimierung dieser Andere sind. Schlussendlich gelang es mir noch unter Nutzung von AVX2, einem speziellen Befehlssatz, in C++ eine 4x schnellere Version als die standardmäßig Vorhande zu entwickeln was mir zeigte, dass es im Gebiet der Codeoptimierung noch viel zu entdecken und zu testen gibt. Im breiteren Kontext gesehen, sind Optimierungen hilfreich, um die Ausführung von Programmen aller Art zu Optimierungen, was zur Einsparungen von monetären und natürlichen Ressourcen führen kann und konkret bei Unternehmen den Gewinn vervielfachen kann.

Inhaltsverzeichnis

| 1 | Einleitung | 4 |
|---|---|-------|
| 2 | Vorgehensweise, Materialien, Methode2.1 Vorgehen2.2 Materialien2.3 Methode2.4 Schwierigkeiten | 6 |
| 3 | Ergebnisse | 8 |
| 4 | Diskussion | 11 |
| 5 | Zusammenfassung | 12 |

1 Einleitung

Im Informatik Leistungskurs des 12. Jahrgangs beschäftigten wir uns nach den Herbstferien mit der Laufzeit von Algorithmen am Beispiel der Quicksort, einem Sortieralgorithmus. Nach diesem thematischen Impuls ergab sich mein Projekt zur Erforschung von Sortieralgorithmen, in dem ich es mir zuerst zur Aufgabe gemacht hatte, den schnellsten Weg zu finden, 10 Millionen zufällig generierte Zahlen zu sortieren. Mein Fokus änderte sich dann allerdings und ich fokussierte mich auf die Aspekte der Implementation und tatsächlichen Ausführung der Programme, da Sortieralgorithmen algorithmisch bereits sehr weit erforscht sind und man in diesem Gebiet nur sehr schwer neue Erkenntnisse sammeln konnte [22]. Ich entschied mich deswegen, nicht nach besseren Algorithmen zu suchen, sondern nach Wegen, mein ursprüngliches Program in Python in seiner Ausführung zu beschleunigen und so vorteilhafte Wege der Geschwindigkeitsoptimierung zu entdecken. Ich stellte mir die Frage, welche Optimierungen die Ausführgeschwindigkeit von Programmen am meisten erhöhen und wieso? Zum Thema der Optimierung fand ich im Bezug auf Python einige Bibliotheken im Internet, die bessere Performance versprachen, von denen ich einige auswählte, um herauszufinden, welche dieser den größten Geschwindigkeitsboost bringt. Außerdem entschied ich mich noch dazu, einige Algorithmen auch in C++ zu implementieren, wobei ich im Bezug darauf nicht direkt Möglichkeiten und Erklärungen fand, welche Modifikationen ein Program schneller machen und wieso diese Veränderungen es schneller machen. Weiterführend verglich ich noch, wie sich meine C++ Programme mit denen in Python in der Ausführung auf einer tiefergreifenden Stufe unterschieden, um herauszufinden, wieso C++ meist deutlich schneller ist. Meine Erwartung war dabei, dass C++ bei jeder Aufgabe Python um ein vielfaches übertrifft im Punkt der Geschwindigkeit, da Python im allgemeinen als langsam gilt und C++ als sehr performant und schnell.

2 Vorgehensweise, Materialien, Methode

2.1 Vorgehen

Meine Vorgehensweise beruhte darauf, mich im Internet über Möglichkeiten der Optimierung zu informieren und diese geschickt neu zu kombinieren und die erreichten Geschwindigkeiten miteinander zu vergleichen, wodurch ich eine Qualitative Entscheidung treffen konnte, welche Variationen die größten Performanceverbesserungen bringen. Dazu wählte ich die Python Bibliotheken numpy, numba, ctypes und cython und testete auch Funktionen aus den Standardbibliotheken der Sprachen. Bei der Implementation nutzte ich Internetquellen wie Stackoverflow, die Cython Dokumentation und andere (alle Seiten aufzuzählen ist nicht zielfführend), um die Implementierung umzusetzen, da ich noch kaum Erfahrung mit diesen Bibliotheken hatte [23d] [23a]. Dies wurde besonders wichtig beim implementieren in den mir noch kaum bekannten Sprachen Java, Lua, Julia und Go. Meine Implementationstechnik war das iterative Implementieren, wo ich eine Startversion immer wieder abwandelte und konstant Dinge änderte. Dabei behielt ich immer die Ausführungszeit im Auge und entschied so, welche Ansätze weitere Tests erforderten. Bei der Implementation einer Radixsort, einem sehr schnellen Sortierverfahren, nutze ich außerdem 2 Publikationen zur Verbesserung meiner eigenen Variante und schuf so die Untergrenze all meiner getesteten Implementationen [Ter00] [Her01]. Im Zuge dessen beschäftigte ich mich auch mit dem Konzept von AVX2 und nutze diesen erweiterten Befehlssatz, den ich im Rahmen der Ergebnisse noch weiter beschreiben werde. [23c] [Sca16].

2.2 Materialien

Für mein Projekt nutze ich meinen Desktop PC (Linux) und meinen Laptop (Linux) zur Implementation und Ausführung der Programme. Dabei nutze ich verschiedene Arten von Software zum entwickeln und Ausführen meiner Programme und zum erstellen meiner schriftlichen Arbeit.

Ich nutze dabei diese Software in der jeweiligen Version:

- Visual Studio Code (Editor f
 ür Code)
- LATEX(Erstellen der Dokumentation)
- clang++ 14.0.6 (C/C++ Compiler)
- python 3.10.8 (Ausführen der Dateien)
- java 19.0.1 openjdk (Javac, JVM)
- lua 5.4.4 (Ausführen der Dateien)
- nodejs 18.8.0 (Ausführen der Dateien)
- julia 1.8.3 (Ausführen der Dateien)
- go 1.19.4 (Compilierung)

2.3 Methode

Meine Methode war das strukturierte Testen und vergleichen von Programmimplementationen und ihrer Variationen mithilfe einer einfachen Zeitname. Ich nutze die Möglichkeiten der jeweiligen Programmiersprachen, um die Ausführungszeiten auf die Milisekunde genau oder sogar genauer zu bestimmen und so zu vergleichen zu machen. In Python definierte ich mir dafür eine eigene Klasse (Abb. 1), fügte das Starten und Stoppen des Timers meinem code hinzu (Abb. 2) und ließ mir die Ergebnisse als Text ausgeben (Abb. 3). Damit die Ergebnisse vergleichbar sind, implementierte ich immer auf ähnliche Weise die Algorithmen und nutze die gleichen Eingabewerte und Konstanten. Als Beispiel generierte ich mir in jeder Sprache eine Liste aus 10 Millionen Zufallszahlen, was ich nicht in die Zeit mit einbezog, und wendete auf diese dann die implementierten Algorithmen an. So hatten alle Programme die Gleiche Aufgabe zu lösen, wodurch Vergleichbarkeit gewährleistet ist. Wichtig war auch, die finalen Tests direkt nach einem Neustart des PCs ohne andere laufende


Programme zu machen, damit es durch variierende Prozessorauslastung keine Verfälschungen gab.


Abb. 1


2.4 Schwierigkeiten


Die größte Schwierigkeit war, dass ich auf diesem Themengebiet noch nicht sehr viel Vorerfahrung hatte. Außerdem waren die Konzepte teils komplex und es war nicht immer einfach, im Internet gute Beispiele zur Implementierung zu finden. Vor dem Projekt hatte ich mich z. B. noch nie mit der Python Bibliothek ctypes"beschäftigt und deshalb fand ich meist erst nach längerem Suchen im Internet eine Lösung für auftretende Fehler. Auch bei der Implementation von Programmen in C++ hatte ich teils meine Schwierigkeiten, da das Verstehen von einigen Bitoperationen erstmal ein eindenken in die Thematik erforderte. Mit dem Ausführen der Programme hatte ich hingegen kaum Probleme. Ein für mich nicht lösbares Problem war auch die Implementierung in Go, wo nur dass generieren einer 7 Millionen Zahlen langen Liste möglich, da bei mehr Zahlen mehr Arbeitsspeicher benötigt wurde, als Go in einem Programmteil erlaubt. Der hohe Verbrauch an Arbeitsspeicher kommt meinen Vermutunge nach von der Implementation von Recursion in Go, die nicht für sehr Tiefe Rekursion geeignet scheint [23b] [tpa20].

3 Ergebnisse









Zufallszahlengenerierung Langsam NumPy numba c++, ctypes Vergleich der Sprachen

4 Diskussion

5 Zusammenfassung

Literaturverzeichnis

- [Ter00] Pierre Terdiman. "Radix Sort Revisited". In: (2000). URL: http://codercorner.com/RadixSortRevisited.htm (besucht am 11.01.2023).
- [Her01] Michael Herf. "Radix Tricks". In: (2001). URL: http://stereopsis.com/radix. html (besucht am 11.01.2023).
- [Sca16] Matt Scarpino. "Crunching Numbers with AVX and AVX2". In: (2016). URL: https://www.codeproject.com/articles/874396/crunching-numbers-with-avx-and-avx.
- [tpa20] tpaschalis. "What is a goroutine? What is their size?" In: (2020). URL: https://tpaschalis.me/goroutines-size/.
- [22] Sortierverfahren. 2022. URL: https://de.wikipedia.org/wiki/Sortierverfahren (besucht am 11.01.2023).
- [23a] Cython Dokumentation. 2023. URL: http://docs.cython.org/en/latest/.
- [23b] Go stack limit reached on deep Recursion. 2023. URL: https://stackoverflow.com/questions/69625277/runtime-goroutine-stack-exceeds-1000000000-byte-limit.
- [23c] Intel AVX2 Dokumentation. 2023. URL: https://www.intel.com/content/www/us/en/develop/documentation/cpp-compiler-developer-guide-and-reference/top/compiler-reference/intrinsics/intrinsics-for-avx2/intrinsics-for-shuffle-operations-1/mm256-shuffle-epi8.html.
- [23d] Stackoverflow. 2023. URL: https://stackoverflow.com/.